

文章编号:1004-3918(2017)02-0227-07

基于神经网络与时空序列的混合模型 在变形监测中的应用

柳新强¹, 王涛^{1,2}, 焦佳爽²

(1. 陕西铁路工程职业技术学院, 陕西 渭南 714099; 2. 长安大学 地质工程与测绘学院, 西安 710054)

摘要: 在变形数据分析与建模中,同时考虑变形体测点之间的时间相关性以及空间相关性的时空序列模型(STARMA)能够更好地反映出变形体的形变规律,但STARMA模型是建立在线性平稳模型基础上的,且大多数观测数据序列是非平稳过程,这给时空序列模型的应用带来了局限性。由于BP神经网络具有很强的非线性映射能力,基于此,结合这两种模型的特点,构造ANN+SRATMA混合模型来处理非平稳序列。通过对建筑物的沉降观测进行分析研究,结果表明了混合模型要优于单一模型,具有很好的实用性。

关键词: 非平稳时空序列; STARMA模型; BP神经网络; 沉降监测

中图分类号: P 258 **文献标识码:** A

Application of Hybrid Model Based on Neural Network and Space-time Series in Deformation Monitoring

LIU Xinqiang¹, WANG Tao^{1,2}, JIAO Jiashuang²

(1. Shaanxi Railway Institute, Weinan 714099, Shaanxi China;

2. College of Geology Engineering and Geomatics, Chang'an University, Xi'an 710054, China)

Abstract: In the area of deformation data analysis and modeling, space-time series model (STARMA) considers the time correlation as well as the spatial correlation among the points, which can describe the laws of deformation better, however, STARMA model is based on the linear stationary series, and most of the observed data series are non-stationary, so this brings limitation to the application of the space-time series model. As BP neural network has strong nonlinear mapping ability, in view of the above, combined with the characteristics of the two models, we construct SRATMA+ANN mixture model to deal with non-stationary sequences. According to the analysis of the settlement observation of buildings, the results show that the hybrid model is better than the single model and has a good practicality.

Key words: non-stationary space-time series; STARMA model; BP neural network; subsidence monitoring

目前多种预测方法应用于变形分析中,使用较为广泛的主要有回归分析^[1-2]、时间序列分析^[3-4]、灰色系统理论^[5-6]、人工神经网络^[7-8]以及这些模型之间的组合运用^[9-10]等等。时空序列建模是在时间序列的基础上拓展到空间上进行分析,即多个时间序列之间存在空间相关关系^[11]。时空序列模型(STARMA)在处理时空过程机理不清楚、多因素时空变量影响的情况时具有较好的效果,在区域交通分析^[12]、森林防火^[13]、遥感影像预测^[14]等方面已经有了成功的运用。近年来,郑姗姗等^[15]将改进的STARMA模型运用到北京城区降雨积水的拟合和短期预测,取得了较好的效果;王尚北等^[16]提出了基于样本驱动的空间权重矩阵确定方法来建立

收稿日期: 2016-09-20

基金项目: 陕西省教育厅科研专项资助(14JK1167); 陕西铁路工程职业技术学院科研基金项目(KY2016-47)

作者简介: 柳新强(1990-),男,助教,硕士,主要从事精密工程测量研究。

STARMA 模型并验证了其有效性;此外,STARMA 模型也运用到了机场噪声^[17]以及瓦斯浓度预测^[18]等方面。

在变形分析方面,李世鹏^[19]针对管线垂直位移建立时空序列模型,并与时间序列模型进行比较,得出 STARMA 模型在时间预测上精度优于 ARMA 模型的结论,李广春等^[20]将时空自回归模型运用到大坝水平位移预测,验证了 STARMA 模型具有空间预测能力等等。由于变形观测序列多数是非平稳序列,而 STARMA 模型不能直接用于非平稳时空序列建模,一般的处理方法是采用差分法消除趋势项,但这种处理可能会消除掉测点间存在的有用信息。BP 神经网络具有很强的非线性处理能力,在解决背景知识不清楚,推理规则不明确而且信息十分复杂的问题时,具有独特的优越性^[21]。基于此,本文建立基于 BP 神经网络与时空序列的混合模型,然后以沉降监测为例对模型的实用性进行分析验证。

1 混合建模思想与步骤

一个非平稳时空序列过程可以表示为:

$$z_i(t) = \mu_i(t) + e_i(t), \quad (1)$$

$$\mu_i(t) = f(i, t), \quad (2)$$

式中: $i \in D \subset R^d$, $t \in T \subset R$; $z_i(t)$ 为序列在时间 t 和空间位置 i 的观测; $\mu_i(t)$ 为大尺度确定性的时空趋势,它能够表示为空间位置 i 和时间 t 的非线性函数;残差项 $e_i(t)$ 是指均值为零的时间相关误差,表示小尺度随机的时空变异。

由于非平稳时空序列由确定性因素和随机性因素两部分构成,因此,可以用确定性模型描述序列中确定性因素的变化规律,用 STARMA 模型刻画序列中随机因素的一般规律,从而建立起确定性加随机性的组合模型。在组合模型中,既有确定部分,又有随机部分,因而用它来描述式(1)的非平稳时空序列往往能得到比较满意的效果。根据混合建模的思想,下面介绍基于 BP 神经网络的混合模型对非平稳时空序列建模的过程。

1.1 BP神经网络提取趋势项

BP 算法是一种梯度下降的监督学习算法,利用经验风险最小化原则计算神经网络输出值与实际值之间的误差。在非平稳时空序列中,需要提取序列中的时空趋势,这里建立的模型是效应量(位移值)关于时间 t 和空间位置 i 的函数,采用一个隐含层和一个输出层对神经网络进行建模,得到时空趋势项 $\hat{\mu}_i(t)$ 的模型函数,表示为

$$\hat{\mu}_i = f\left(\sum_{k=1}^n \beta_k f(i, t) + \beta_0\right), \quad (3)$$

式中: i 为空间位置,它由经度 x 和纬度 y 构成,在变形监测数据中, i 可以用该点的平面(绝对或相对)坐标来表示; t 表示的是当前时间,即监测时间。为了方便计算,转换为相对时间, T 表示监测期数,如下式:

$$t_0 = 1, \quad t_1 = 1 + 1/T, \dots, \quad t_j = 1 + j/T \quad (j = 1, 2, \dots, T), \quad (4)$$

其中: n 是隐层节点的数目; $\hat{\mu}_i$ 为在空间位置 i 和时间 t 的预测值; f 是隐层的非线性传递函数; β_k 为连接函数, β_0 为阈值。

1.2 STARMA 建模残差序列

去除位移趋势项以后的残差采用 STARMA 模型进行分析。根据式(1),在去除非平稳时空序列中大尺度非线性的时空趋势后,得到小尺度随机时空变异,即残值 $e_i(t)$ 。首先对残值 $e_i(t)$ 进行检验,也就是说残差序列是否时空平稳,如果是,则用 STARMA 建模,采用 STARMA 对 $e_i(t)$ 建模的表达式为

$$e_i(t) = \sum_{k=1}^p \sum_{h=0}^{m_k} \varphi_{kh} \mathbf{W}^{(h)} \mathbf{e}(t-k) - \sum_{l=1}^q \sum_{h=0}^{n_l} \theta_{lh} \mathbf{W}^{(h)} \varepsilon(t-k) + \varepsilon(t), \quad (5)$$

式中: $\mathbf{e}(t)$ 表示时间 t 的 $N \times 1$ 向量,可以描述为 $\mathbf{e}(t) = [e_1(t), e_2(t), \dots, e_N(t)]$; p 表示自相关(时间)阶数; q 表示移动平均(时间)阶数; m_k 表示第 k 个自相关项的空间阶数; n_l 表示第 l 个移动平均项的空间阶数; φ_{kh} 表示需要估计的时间延迟 k 且空间延迟 l 项的自相关系数; θ_{lh} 表示需要估计的时间延迟 l 且空间延迟 h 项的移动平

均系数; $W^{(h)}$ 表示 h 阶空间邻接的 $N \times N$ 权重矩阵, 值得注意的是, 当 $h=0$ 时, $W^{(0)} = I$; $\varepsilon(t)$ 表示时间 t 的随机正态分布误差向量, 即 $\varepsilon(t) = [\varepsilon_1(t), \varepsilon_2(t), \cdots, \varepsilon_n(t)]'$.

STARMA 模型的建立. STARMA 模型的建模步骤与时间自相关移动平均模型类似, 由如下三个过程组成^[22]:

- ①模型辨识. 通过时空自相关函数和时空偏自相关函数确定模型的大致方向, 选择合适的模型作为建模的候选模型, 并确定模型的阶数.
- ②参数估计. 通过求解方程来确定模型参数值.
- ③模型诊断. 通过对原时间序列与所建模型之间的误差序列是否满足随机误差检验来实现, 检查在近似的置信区间内参数估计的统计显著性, 若检验不能通过, 转回①重新辨识模型.

2 工程实例分析

本文选取了位于隧道周边的一栋建筑物. 随着隧道施工的推进, 及时对隧道周边的建筑物进行实时的沉降和倾斜的监测, 有着极为重要的意义, 是整个隧道工程监测部分中极其重要的一方面, 是确保周边建筑物和居民生命财产安全的有力保障. 该建筑物建设时间较早, 为8层砼结构. 在隧道施工期间, 对该建筑物进行了周期性的沉降观测. 监测点均匀布设在建筑物的四周主体墙面底部(分布如图1所示).

利用徕卡高精度电子水准仪 Sprinter 250M 对该建筑物进行沉降观测, 通过对监测资料进行计算和整理, 得到了各测点的累积沉降量, 各点累积沉降变化曲线如图2所示, 为了便于比较出各测点的时间序列, 将各点的沉降值逐次加同一个常数5. 本文选取了 $D_1 \sim D_6$ 六个监测点的20期监测数据作为建模数据进行研究.

2.1 BP神经网络提取时空趋势

从图2中可以明显看出 $D_1 \sim D_6$ 观测数据为非平稳时空序列, 为此, 利用BP神经网络提取时空趋势.

这里选择构造一个三层的神经网络, 其中输入层包含3个输入参数, 分别为表示空间位置的平面坐标 x, y 和相对时间 $t-1$, 在训练之前, 数据采用归一化处理到 $[-1, 1]$ 之间, 以便于网络的收敛, 然后一个隐层包含5个双正切S型转换函数, 函数输出范围也为 $[-1, 1]$, 1个输出层代表累积沉降量.

在该网络中, 归一化后的 x, y 以及 $t-1$ 构成 100×3 的输入矩阵, 所对应的累积沉降量构成 100×1 的目标矩阵, 以此构造样本, 利用MATLAB进行编程, 限定误差标准为0.001, 然后对样本进行学习, 训练结果如图3所示.

从图3网络训练误差变化曲线图中可以看到, 当训练步数达到第104步时就已达到期望精度.

万方数据




图1 监测点位示意图

Fig.1 Schematic diagram of monitoring points




图2 监测点 $D_1 \sim D_6$ 累积沉降变化示意图

Fig.2 Schematic diagram of cumulative settlement changes of $D_1 \sim D_6$

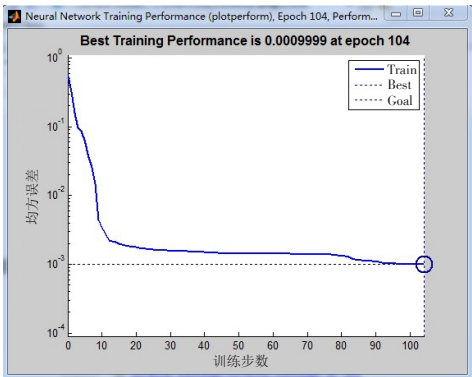


图3 BP神经网络训练误差图

Fig.3 BP neural network training error bar

2.2 残差序列建立STARMA模型

利用训练好的BP神经网络提取趋势项后,得到各监测点残差序列.

从图4中可以看到,BP神经网络提取趋势项后,残差序列已是近于平稳序列(为方便进行比较,逐次对各点减去同一常数1),然后建立空间权重矩阵.由于监测点在建筑物上较均匀分布(图1),且测点间距离不大,可考虑根据邻接关系或者距离信息建立空间权重矩阵,本文采用建立二进制邻接矩阵.

计算该序列8阶时间延迟和3阶空间延迟的时空自相关系数和偏自相关系数,结果分别见表1和表2.

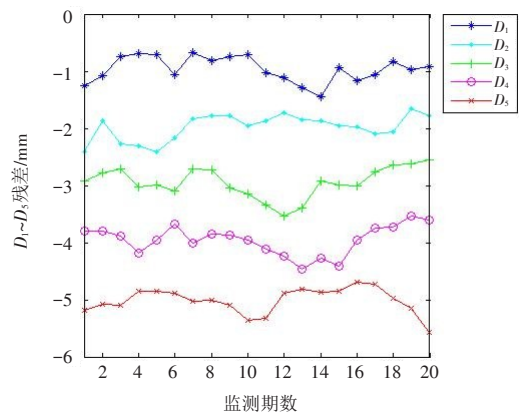


图4 残差序列图

Fig.4 Residual sequence diagram

表1 样本残差的时空自相关系数

Tab.1 Temporal and spatial autocorrelation coefficients of sample residuals

时延 k / 空延 h	0	1	2	3
1	0.562 4	0.347 3	0.241 9	-0.209 4
2	0.479 8	0.266 9	0.177 3	-0.172 0
3	0.380 9	0.182 2	0.118 9	-0.063 0
4	0.349 1	0.089 8	0.066 1	-0.103 6
5	0.272 0	0.152 8	-0.090 9	-0.095 2
6	0.203 3	-0.164 1	-0.132 4	-0.086 4
7	0.176 8	-0.204 3	-0.135 1	-0.064 1
8	0.127 7	-0.278 5	-0.112 6	-0.016 5

表2 样本残差的时空偏自相关系数

Tab.2 Temporal and spatial partial autocorrelation coefficients of sample residuals

时延 k / 空延 h	0	1	2	3
1	0.562 4	0.137 5	0.031 0	0.083 8
2	-0.111 9	0.111 2	-0.038 3	0.058 1
3	-0.159 9	0.125 0	-0.041 0	-0.132 2
4	-0.008 5	0.031 9	-0.012 1	0.002 3
5	-0.025 9	-0.000 8	-0.012 1	0.002 3
6	-0.052 6	-0.095 6	-0.121 0	0.053 7
7	-0.046 9	0.027 6	0.016 7	0.048 5
8	-0.007 4	0.079 3	0.020 8	-0.013 9

通过对表1和表2分析发现,偏相关系数在3阶时间延迟和1阶空间延迟以后迅速接近于0,在验证该时空序列是平稳序列的同时,也可知模型为STAR(3,1)^[22],即:

$$z(t)=\sum_{k=1}^3\sum_{h=0}^1\varphi_{kh}W^{(h)}z_{t-k}+\varepsilon(t).$$

(6)

然后利用残差序列,对该模型进行最小二乘估计,得到STAR(3,1)模型的参数值及检验结果,列于表3中.

表3 模型参数估计及其检验

Tab.3 Model parameter estimation and test

项目	φ_{10}	φ_{11}	φ_{20}	φ_{21}	φ_{30}	φ_{31}
参数估值	0.742 1	0.066 7	-0.099 2	-0.033 0	-0.134 0	0.056 1
t 检验	76.889	7.846	10.225	3.541	12.438	7.021
p 值	0	0	0	0.001 1	0	0

从表中可以看出,所有参数 p 值均明显小于 0.05,表明参数均通过 t 检验,则序列最终的时空序列模型为

$$z(t)=0.742\ 1\boldsymbol{W}^{(0)}z(t-1)+0.066\ 7\boldsymbol{W}^{(1)}z(t-1)-0.099\ 2\boldsymbol{W}^{(0)}z(t-2)-$$
$$0.033\ 0\boldsymbol{W}^{(1)}z(t-2)-0.134\ 0\boldsymbol{W}^{(0)}z(t-3)+0.056\ 1\boldsymbol{W}^{(1)}z(t-3)+\varepsilon(t).$$

(7)

同样,为了判断所得到的模型是否能够解释数据中的时空变异,需要计算模型残差的时空自相关函数,如果残差序列时空相关函数均值近似为0,方差小于 $[N(T-s)]^{-1}$ (式中, N 表示空间单元的数目, T 表示期数, s 代表时间延迟),表明残差序列接近于随机误差,表4给出了模型(7)残差的时空自相关函数.

表4 模型(7)残差的时空自相关系数

Tab.4 Temporal and spatial partial autocorrelation coefficients of model(7)

时延 k / 空延 h	0	1	2	3
1	-0.113 5	-0.062 3	0.006 2	-0.007 8
2	-0.117 6	-0.012 2	0.027 3	0.020 2
3	0.181 6	0.054 2	-0.079 6	-0.001 7
4	0.014 1	0.042 3	-0.015 9	-0.015 3
5	-0.008 1	0.084 2	0.019 3	0.026 1
6	-0.028 0	0.007 4	-0.007 4	-0.000 5
7	0.013 9	0.028 5	-0.053 5	0.010 4
8	0.003 7	0.004 1	0.002 7	0.001 4

由表4可知, s 取3,计算 $[N(T-s)]^{-1}=[5\times(20-3)]^{-1}=0.012$,表4中,所有值的均值和方差计算结果分别为0.000 7(近似为0)和0.003 1,即时空自相关函数值的均值和方差都很小,基本满足模型诊断准则,也表明残差在时间上和空间上不存在显著的自相关,得到模型(7)可以较好地表示提取趋势项后的数据序列.

对模型(7)进行计算,对4~20期观测值进行拟合(因时间延迟期为3,所以从第4期开始)并进行后5期(21~25期)预测,结果见于图5.

进一步计算各点的拟合与预测的均方根误差(RMSE)值,结果见表5.

表5 混合模型和STARMA模型拟合预测精度评估

Tab.5 Fitting and prediction accuracy evaluation of hybrid model and STARMA model

点号	拟合 RMSE		精度提高/%	点号	预测 RMSE		精度提高/%
	混合模型	STARMA			混合模型	STARMA	
D_1	0.185 9	0.201 8	8.55	D_1	0.240 2	0.321 9	25.38
D_2	0.142 6	0.173 1	17.62	D_2	0.184 8	0.282 7	34.63
D_3	0.196 0	0.203 8	3.83	D_3	0.253 6	0.330 1	23.17
D_4	0.194 4	0.261 6	25.69	D_4	0.239 6	0.274 8	12.81
D_5	0.186 5	0.228 9	18.52	D_5	0.208 3	0.284 7	26.84

从表5中可以发现,混合模型的拟合均方根误差比起SRARMA模型有了一定程度的下降, $D_1\sim D_5$ 的RMSE值分别减少了8.55%、17.62%、3.83%、25.69%和18.52%,说明混合模型的拟合结果要略优于STARMA模型;从预测精度上看,相比较于STARMA模型,混合模型中, $D_1\sim D_5$ 的RMSE值分别下降了25.38%、34.63%、23.17%、12.81%和26.84%,说明混合模型有更好的预测性能. 综上所述,充分考虑到沉降变化的时空性以及非线性的ANN+STARMA混合模型要优于单一的STARMA模型.

3 结论

1)STARMA模型同时考虑了测点之间的时间相关性和空间相关性,能够更好地反映变形规律,但STARMA模型仅能建模平稳时空序列,针对非平稳时空序列,由于测点之间存在空间相关性,采用传统差分法可能会消除掉测点间空间联系,进而会影响最终的结果,因此当测点之间的空间关系是连续时不宜采用.

2)BP神经网络与时空序列模型进行组合建模可以很好地处理非平稳序列,理论依据是BP神经网络能够提取出序列中隐含的非线性时空趋势,通过与STARMA模型计算结果分析比较发现,所提出的混合模型具有更好的拟合与预测能力,进而可以说明ANN+STARMA混合模型在处理非平稳时空序列中具有一定的优势.

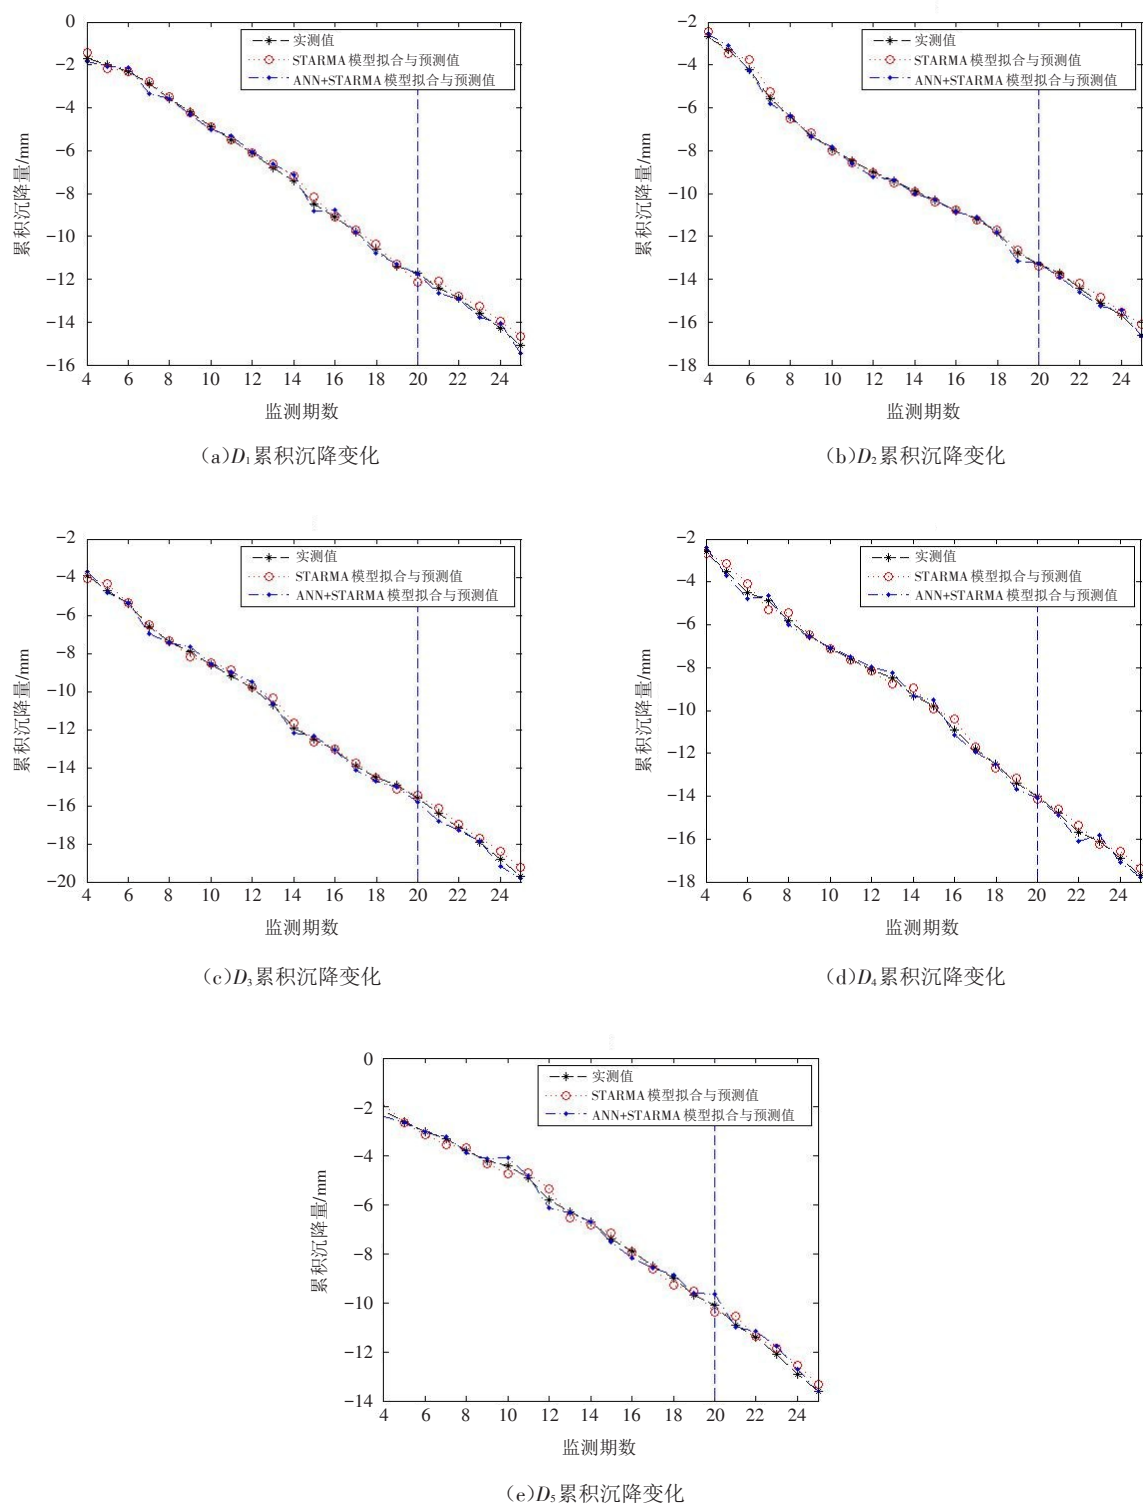


图5 模型结果对比图

Fig.5 Comparison of model results

参考文献:

- [1] 陈晓鹏,张强勇,刘大文,等. 边坡变形统计回归分析模型及应用[J]. 岩石力学与工程学报,2008,27(S2):3673-3679.
- [2] 沈月千,黄腾,陈喜凤,等. 逐步回归分析在桥梁挠度变形预测中的应用[J]. 工程勘察,2012,40(7):79-83.
- [3] 潘国荣. 基于时间序列分析的动态变形预测模型研究[J]. 武汉大学学报(信息科学版),2005,30(6):483-487.
- [4] 臧妻斌,黄腾. 时间序列分析在地铁变形监测中的应用[J]. 测绘科学,2014,39(7):155-157.
- [5] 陈伟清. 灰色预测在建筑物沉降变形分析中的应用[J]. 测绘科学,2005,30(5):43-45.
- [6] 冯志,李兆平,李伟. 多变量灰色系统预测模型在深基坑围护结构变形预测中的应用[J]. 岩石力学与工程学报,2007,26(S2):4319-4324.
- [7] 王穗辉,潘国荣. 人工神经网络在隧道地表变形预测中的应用[J]. 同济大学学报(自然科学版),2001,29(10):1147-1151.
- [8] 潘国荣. 地铁隧道变形的神经网络法预测[J]. 大地测量与地球动力学,2007,27(1):80-84.
- [9] 彭涛,杨岸英,梁杏,等. BP神经网络-灰色系统联合模型预测软基沉降量[J]. 岩土力学,2005,26(11):1810-1814.
- [10] 高彩云,高宁. 基于时序AR(p)-RBF神经网络的变形建模与预测[J]. 测绘科学,2013,38(6):120-122.
- [11] KAMARIANAKIS Y, PRASTACOS P. Space-time modeling of traffic flow[J]. Computers and Geosciences, 2005, 31(2): 119-133.
- [12] 韩卫国,王劲峰,高一鸽,等. 区域交通流的时空预测与分析[J]. 公路交通科技,2007,24(6):92-96.
- [13] 王佳璆,程涛. 时空预测技术在森林防火中的应用研究[J]. 中山大学学报(自然科学版),2007,46(2):110-113.
- [14] CRESPO J L, ZORRILLA M, BERNARDOS P, et al. A new image prediction model based on spatio-temporal techniques[J]. Visual Computer, 2007, 23(6): 419-431.
- [15] 郑姗姗. 城市降雨积水时空序列分析与短时预测的初步研究[D]. 北京:中国科学院大学,2014.
- [16] 王尚北,王建东,陈海燕. STARMA网络时空序列预测模型研究[J]. 计算机应用研究,2014,31(8):2315-2319.
- [17] 王尚北. 基于多噪声监测点机场噪声时空序列预测模型研究[D]. 南京:南京航空航天大学,2014.
- [18] 吴娇娇. 基于时空神经网络模型的瓦斯浓度预测研究[D]. 徐州:中国矿业大学,2015.
- [19] 李世鹏. 基于时空序列模型的变形分析研究[D]. 西安:长安大学,2014.
- [20] 李广春,戴吾蛟,杨国祥,等. 时空自回归模型在大坝变形分析中的应用[J]. 武汉大学学报(信息科学版),2015,40(7):877-881.
- [21] 陶本藻. 测量数据处理的统计理论和方法[M]. 北京:测绘出版社,2007.
- [22] 王佳璆. 时空序列数据分析和建模[M]. 北京:科学出版社,2012.

(编辑 张继学)